Mål analys

Här görs målen, NHL 2024.

Oskar Amnér

EC Utbildning

Projekt i Data Science

Oktober-2025

Abstract

Knowledge of how and from where goals are scored in the worlds best hockey league can be utilized to improve the scoring efficiency of both teams and individual players. This study analyzes the types of shots used and the location from which they are taken. The findings are clearly visualized through an interactive streamlit application. Furthermore, a Random forest machine learning model was trained on the dataset to predict whether a shot from a specific position will result in a goal. The model achieved an accuracy of 92.80% and an AUC score of 0.7095.

Innehållsförteckning

Abstract 2
1. Inledning 1
2. Teori 2
3. Metod 4
4. Resultat och Diskussion 5
Resultat 5
Diskussion 9
5. Slutsatser 10
6. Självutvärdering 11

1. Inledning

Flera stora tech profiler pratar om en framtid där framstegen inom AI gör att arbeta kommer bli valfritt. Om en majoritet av människors vakna tid frigörs från arbete, vad ska människan då ägna tiden åt? En solid gissning är att idrott kommer få en större plats i människors vardag. Då människans biologiska instinkt att tävla och mäta oss mot varandra lever kvar inom oss.
Ökat intresse och tekniska framsteg möjliggör datadrivna sportanalyser, som kan användas för att förbättra sporten, lagen och spelarnas skicklighet.
Detta projektarbete fokuseras på idrotten ishockey, NHL har de senaste åren börjat samla in och spara allt fler datapunkter från deras matcher.
Denna ökade tillgång till data kan vara svårtolkad för en vanlig åskådare. Detta arbete ska nu använda datan till att visualisera den, samt utveckla en applikation som beräknar sannolikheten att en skottchans blir till ett mål. Förhoppningsvis hjälpa en spelare till att bli en bättre målskytt. Genom att analysera varifrån målen görs i världens bästa hockeyliga NHL.

Syftet med denna rapport är att bli en bättre målgörare i ishockey, genom mer kunskap om hur och varifrån målen görs i NHL.
För att uppfylla syftet så kommer följande frågeställning(ar) att besvaras:

1. Varifrån på isen görs flest mål i NHL?
2. Vilken typ av skott görs det flest mål med?

2. Teori

Ishockey går likt många andra lagsporter ut på att göra flera mål än motståndaren. Denna ständiga kamp mot motståndarna för att vinna duellerna och ta laget till ett bra skottläge, för att få chansen att göra ett mål. När en spelare har tagit sig till ett skottläge, så kvarstår kampen mot motståndarens målvakt som också behöver överlistas, för att pucken till slut ska gå in i mål.
Det finns flera metoder för att överlista en hockeymålvakt, skottet behöver komma ifrån en så bra skottvinkel och avstånd som möjligt. Vilken typ av skott kan också påverka chansen om det blir mål eller ej.

Både hur stor del av skotten som blir mål procentuellt, samt även totala antalet mål som görs har använts som mått. För att ge en heltäckande förståelse.

Sidan med olika skott typer, använder följande förkortningar:

Förklaring av skott-typer:

- **DEFL** (Deflection / Styrning - Passiv)
- **SNAP** (Snap Shot / "Snärtskott")
- **BACK** (Backhand)
- **TIP** (Tip-In / Styrning - Aktiv)
- **WRIST** (Wrist Shot / Handledsskott)
- **WRAP** (Wrap-around / "Köksvägen")
- **SLAP** (Slap Shot / Slagskott)

En Maskininlärningsmodell har skapats och tränats med hjälp av övervakad inlärning, som innebär att det rätta svaret redan finns i datan. Svaret på hur stor chans det är att det blir mål från just det avståndet och den vinkeln finns i NHL datan som använts, och kan därför träna upp modellen.
Utfallet som modellen ger, är ett klassificerings problem, binärt utfall mål eller ej mål, där modellen sedan räknar ut sannolikheten för att det ska bli mål från just det avståndet och den vinkeln du ställer in.
För att modellen inte ska överanpassas till träningsdatan, så delades datan upp i två delar 80/20, där 80% av datan användes för att träna modellen och resterande 20% som då va helt osedd för modellen användes för att testa modellen.

Två olika modeller utvärderades:
- Logistisk regression som är en linjär modell som ofta används som baslinje vid binär klassificering.
- Random forest som är en mer komplex modell som sammanväger flera olika beslutsträd till ett slutgiltigt resultat, vilket är en modell som kan hantera icke linjära samband och minskar risken för överanpassning.

Modellen använder två olika mätvärden.
Accuracy (noggrannhet) visar antalet gissningar som var rätt.
Formel: (antal rätt gissningar) / (Totalt antal gissningar)

AUC Score (Area under Curve – ROC)
Ett mått på hur bra modellen är på att rangordna skotten. Kan den skilja på ett bra läge (hög sannolikhet) och ett dåligt läge (låg sannolikhet)

Skalan:

- 0.5 = Slumpmässig gissning (singla slant).
- 1.0 = Perfekt (gissar alltid rätt).
- 0.7 - 0.8 = Anses ofta som "bra" eller "acceptabelt" för komplexa problem som sportdata.

För en xG-modell är AUC viktigare än Accuracy. Vi vill veta sannolikheten för mål som en procentsats, och inte bara ett ja/nej-svar om det blev mål eller ej.

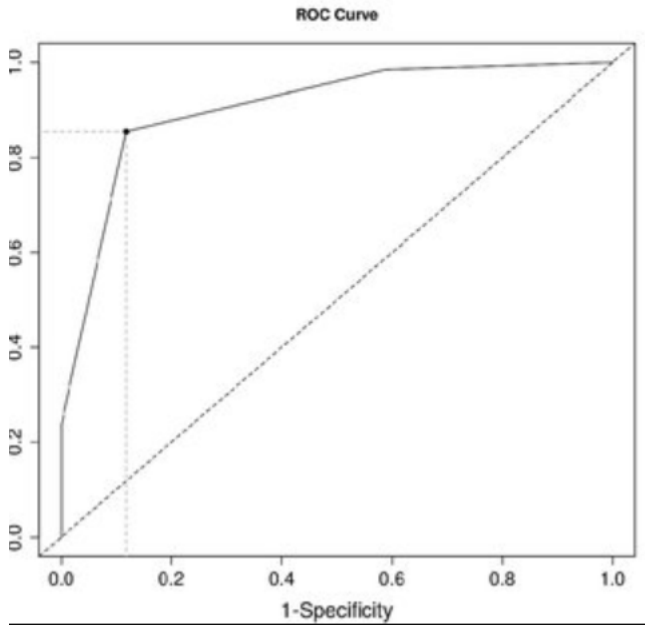

Bilden visar en Roc curve, streckade baslinjen är 0,5 vilket är lika med slumpen. Den heldragna linjen visar ett exempel på en modells prediktion, AUC scoren är arean/ytan under den dragna linjen, desto högre AUC score desto bättre är modellen på särskilja en högkvalitativ målchans.

3. Metod

Verktyg och miljö

Projektet genomfördes i VS studio code med programmeringsspråket Python (version 3.14). För att gå igenom datan och se vad den innehöll så gjordes en första översyn och analys med hjälp av Jupyter Notebooks, via en extension (tillägg) i VS code. Kan ses i filen analys.ipynb, där laddades datan in och experimenterades med olika sätt att visualisera datan, med olika grafer och heatmaps. Python biblioteken Pandas, Matplotlib och Seaborn användes för dataanalys och visualiseringar. Maskininlärningsmodellerna implementerades med hjälp av Scikit-learn. Den interaktiva webbaplikationen utvecklades med Streamlit.

Datainsamling.

Datan som användes i arbetet laddades ner från Monepuck.com, där det gick att hämta en csv fil med väldigt mycket data filtrerad på olika rubriker. Monepuck har ursprungligen hämtat datan från NHL:s officiella API, så den förväntas vara korrekt och pålitlig, och är det huvudsakliga alternativet för inhämtning av data som behövs för denna typ av analys. Filen som laddades ner heter shots_2024.csv, och innehöll detaljerad information om varje skott under NHL säsongen 2024-2025. Filen innehöll skottdata från samtliga lagen i NHL.

Databehandling

Eftersom datan ursprungligen angav avstånd i fot (feet) så skapades en variabel där avståndet konverterades till meter för att anpassas till svenska mått.

Datan filtrerades sedan delvis för att få fram måtten som var relevanta för arbetet, tex på returer, avstånd och skott typ.

Träning av maskininlärnigsmodeller

För att kunna förutsäga sannolikheten för mål, benämnt som Expected Goals (xG), valdes variablerna avstånd och vinkel ut som oberoende variabler (features), medan utfallet om det blev mål eller ej (representerat som ett binärt tal, 1 eller 0) användes som målvariabel (target).

Datasetet delades slumpmässigt upp i två delar, en träningsdel och en testdel.

- Träningsdata 80% användes för att lära algoritmerna sambanden.
- Testdata 20% sparades undan från träningen för att kunna utvärdera modellernas prestanda på osedd data.

Två modeller tränades och jämfördes: en logistisk regression och en random forest classifier. Modellerna sparades sedan som shot_models.pkl fil för att kunna laddas in snabbt i applikationen utan att behöva tränas om vid varje användning.

Utveckling av Webbaplikation

För att göra analysen och prediktionsmodellen tillgänglig på ett smidigt sätt, så byggdes ett grafiskt gränssnitt i Streamlit. Applikationen strukturerades med en sidomeny för att kunna växla mellan olika vyer:

- Översikt (KPI)
- Heatmap: Målchans (%)
- Heatmap: Returer
- Stapel: Skott-typer
- Stapel: Avstånd (Meter)
- AI Prediction: xG model

Översiktsfliken (KPI) visar hur rådatan ser ut, där visas de 10 första raderna. Som man kan scrolla igenom samtliga rubriker som finns. Samt totala antalet skott, antalet mål och hur ofta det blir mål per skott.
De nästkommande fyra sidorna visar relevant statistik i form av stapeldiagram och heatmaps.
Den sista sidan visar en AI prediction en interaktiv flik där användaren via reglage kan ange avstånd och vinkel. De inställda reglagen visualiseras via en puck på en hockeyrink. Dessa inställda värden skickas sedan i realtid till den tränande och valda Random forest modellen, som returnerar en sannolikhet (xG) för att den valda placeringen ska bli mål. Modellens prediktion visas sedan med den procentuella siffran för mål och beskrivning av målchansen.
”låg chans” under 5%, ”hyfsad chans” mellan 5% och 20%, ”Mycket bra målchans” över 20%.

Koden som har använts för projektet finns tillgänglig på github:
github.com/0AAI/Projektarbete_NHL_skott_analys

4. Resultat och Diskussion

Resultat

Datan innehöll totalt 119 870 skott, som användes i analysen. 8428 av dessa skott blev mål, vilket ger en målprocent i snitt på 7,03%.

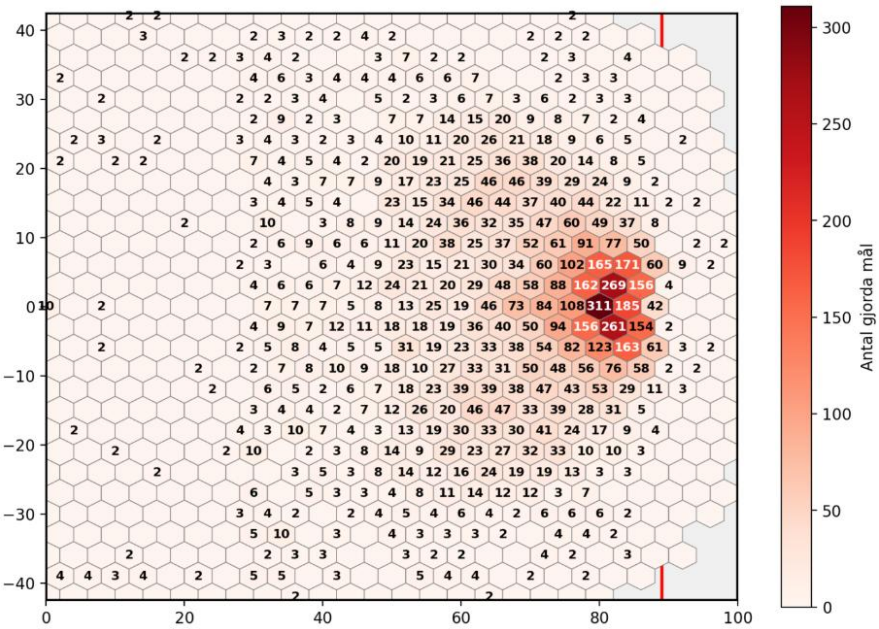

Heatmappen visar varifrån samtliga 8428 stycken målen gjordes ifrån på isen. Visualiseras både med en färg, desto rödare desto mer mål och med de faktiska siffrorna. Allra flest mål gjordes väldigt nära målet. Även placeringen har betydelse, då allra flest mål gjordes rakt framifrån, med max 311 stycken från en enskild ruta rakt framifrån.
Vänster sida (oftast målvaktens stötsida): 91+77+50+102+165+171+60+88+162+269+156 = 1391 stycken.
Höger sida (oftast målvaktens plocksida) : 94+156+261+154+82+123+163+61+56+76+58 = 1284 stycken.
1391 – 1284 = 107 fler mål gjordes på de närmaste 11 rutorna på vänstra sidan av målet.

1284/1391 = 0,923 ungefär 9% fler mål gjordes på de närmaste 11 rutorna jämfört med motsvarande 11 rutor på högra sidan.

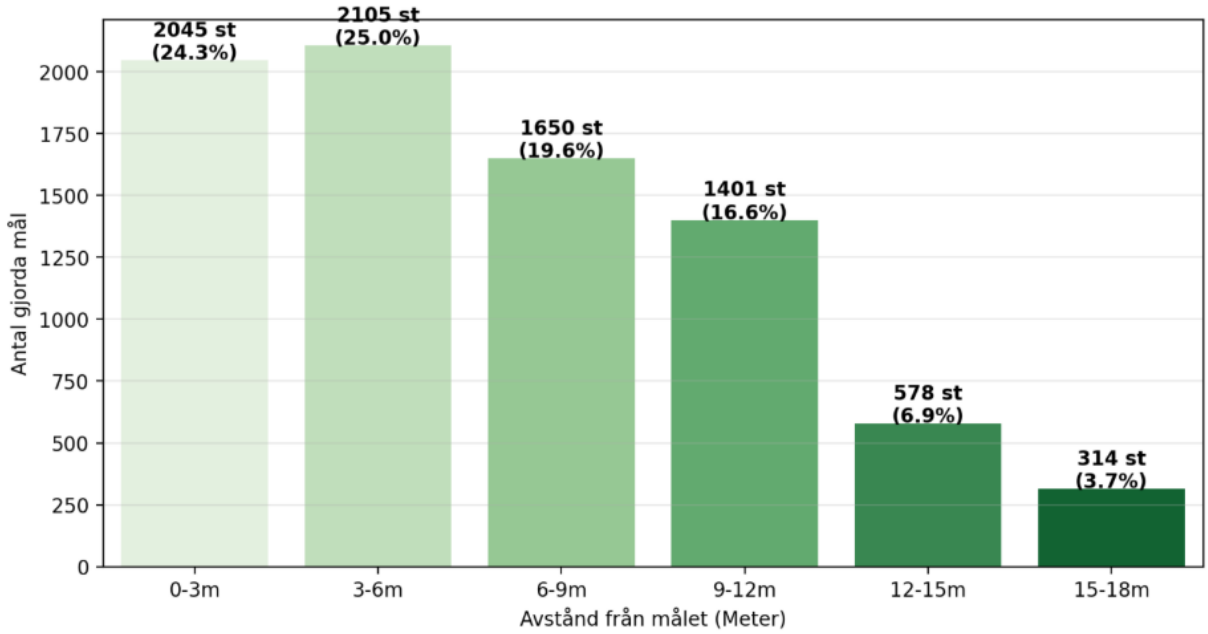

Denna graf tydliggör ytterligare hur stort avståndet ifrån målet har betydelse. Grafen visar de faktiska antalet mål som gjorts från ett visst avstånd. 2045 (24,3%) mål gjordes från 0-3 meter avstånd. Men ännu fler, 2105 (25%) gjordes från 3-6 meter avstånd. Sedan minskar antalet mål successivt desto längre ifrån mål du kommer, med endast 314 (3,7%) stycken mål från de längsta avståndet på 15-18 meter.

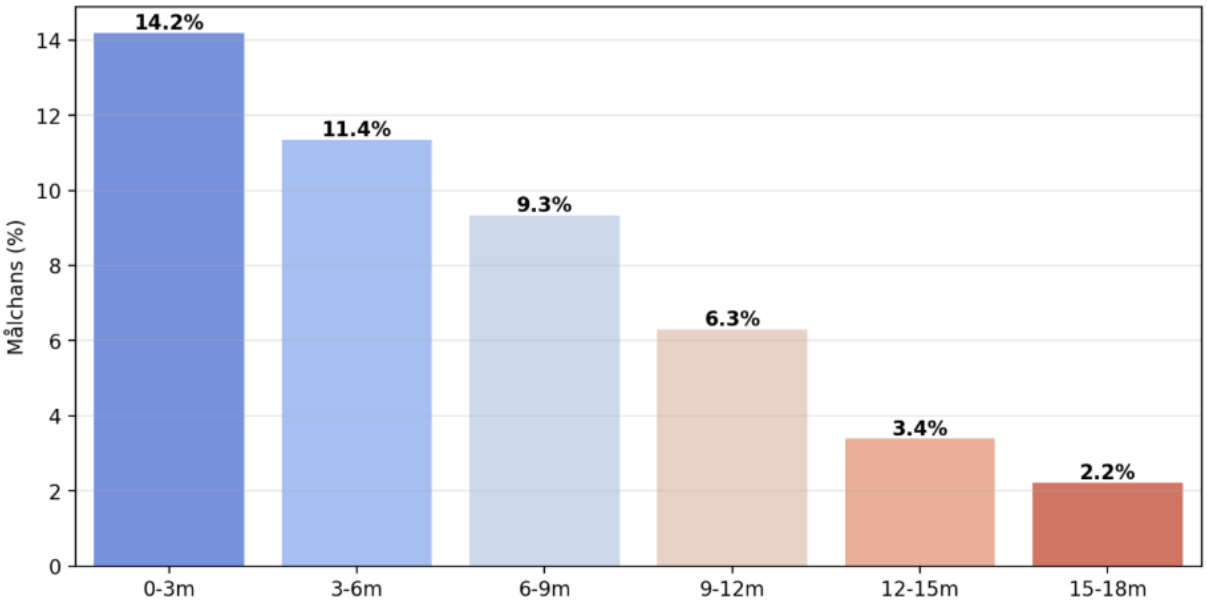

Denna graf visar målprocenten, hur ofta ett skott som tas från följande avstånd blir mål. Allra störst chans att det blir mål är 0-3 meter från målet, då 14,2% av skotten blir mål, följt av 3-6 meter då 11,4% av skotten blir mål. Antalet av skotten som blir till mål minskar successivt ner till 2,2% målprocent på det längsta avståndet 15-18 meter.

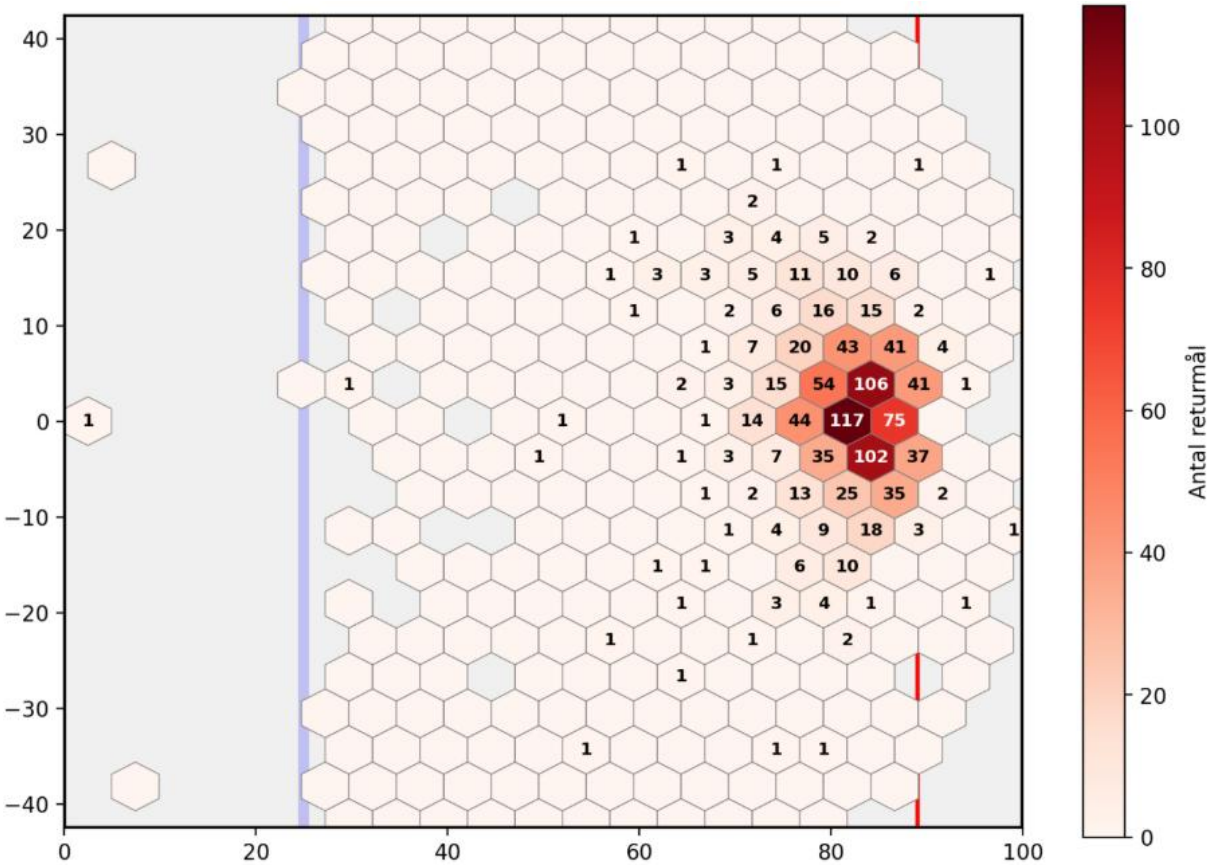

Denna graf visar placeringen av antal mål gjorde från en retur. Totalt 1029 stycken mål var returmål, vilket är ca 12% av samtliga mål (1029/8428 = ca 12%). Returmålen är tydligt centrerade runt målet, Och även märkbart närmare målburen jämfört med heatmapen för alla målen.
Vänster sida(oftast målvaktens stötsida): 41+106+54+15+41+43+20+15+16 = 351 stycken.
Höger sida(oftast målvaktens plocksida): 37+102+35+7+35+25+13+18+9 = 281 stycken.
351-281= 70 stycken fler mål gjordes på de 9 vänstra närmsta rutorna till skillnad från de 9 högra närmsta rutorna. Vilket är ca 20% fler mål på vänstra sidan jämfört mot den högra sidan.

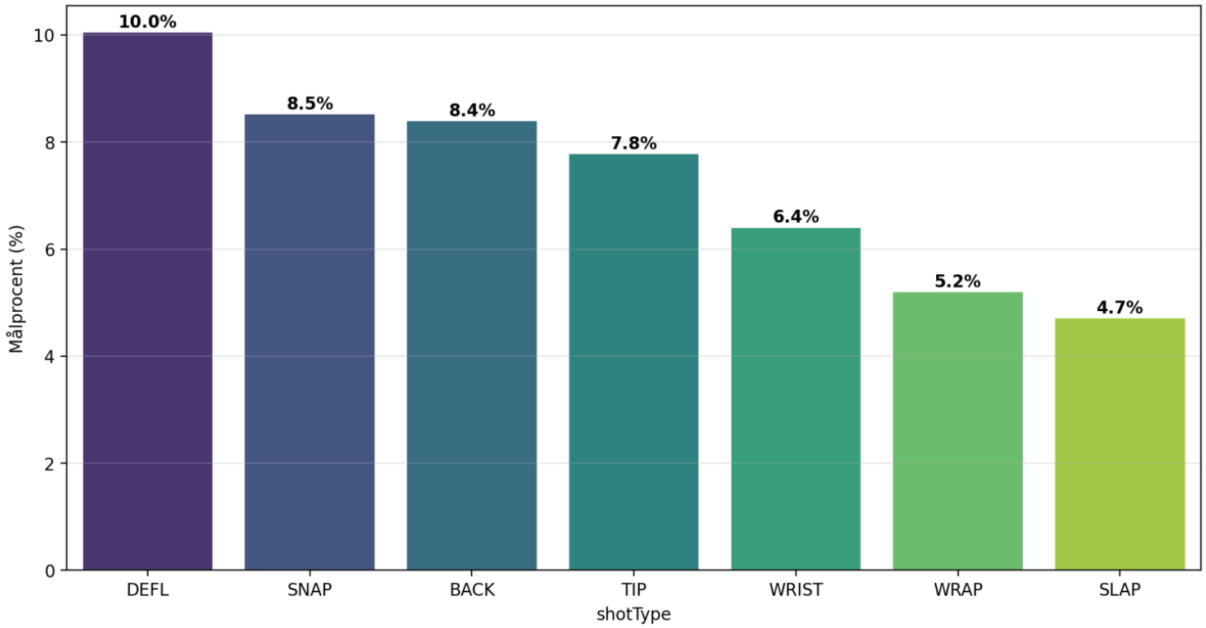

Denna grav visar hur målen har fördelats mellan de olika skott typerna. Den vanligaste skott typen som blir mål är när någon passivt styr/ändrar riktning på ett skott, då hela 10% av målen görs på detta sätt. Sedan följer ett snabbt snärt skott på 8,5%. Sedan minskar andelen mål till lägst 4,7,% som görs via slagskott.

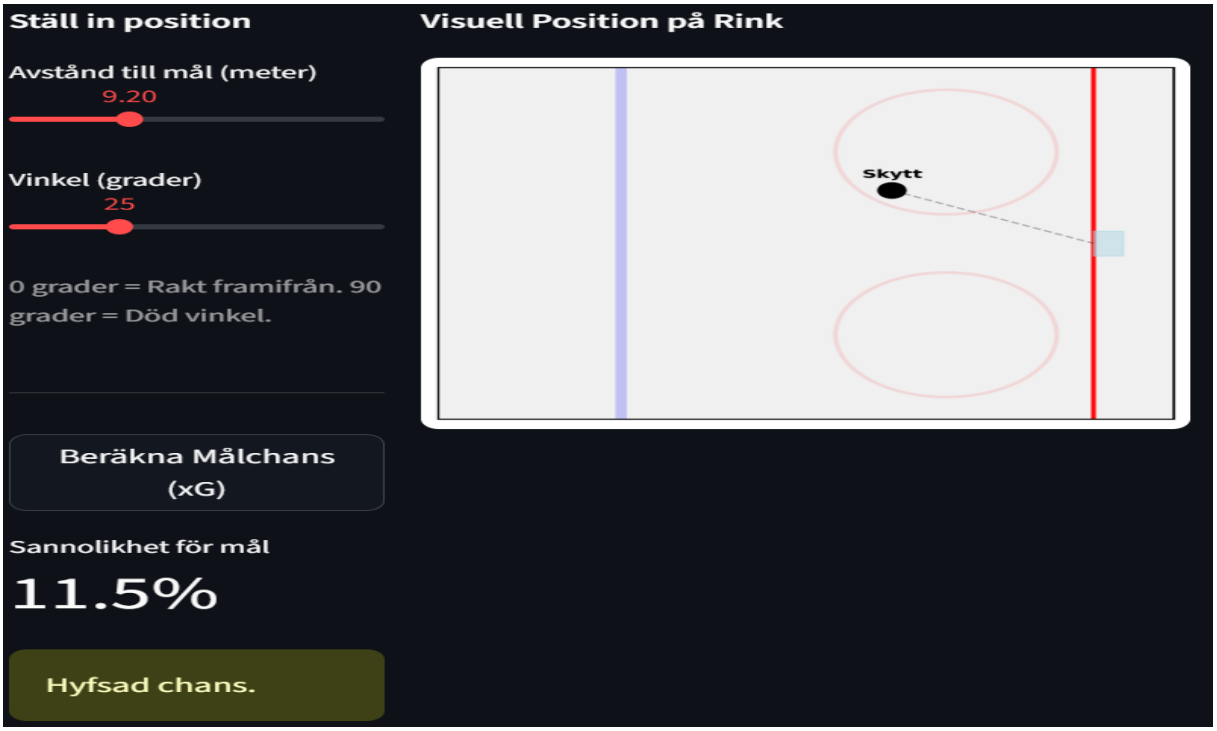

Sista sidan innehåller en maskininlärnings modell som beräknar sannolikheten för att det blir mål från ett visst avstånd och vinkel. Användaren reglerar vinkel och avstånd med reglage, valda positionen visas sedan på rinken. När man sedan trycker på knappen ”Beräkna målchans (xG)”, räknar modellen fram sannolikheten för att det blir mål. Två modeller tränades på datan med likvärdiga resultat. Valde

att gå vidare med Random forest modellen, då den modellen är bäst på att fånga icke linjära samband. Random forest modellens resultat: accuracy 92,80% och med en AUC score på 0,7095. Accuracy innebär att modellen gissar rätt ifall det blir mål eller inte i 92,80% av fallen. AUC score på 0,7095 indikerar att modellen med god marginal är bättre än slumpen på att skilja mellan ett bra skottläge och ofarliga situationer.

Diskussion

Resultaten i denna rapport bekräftar till stor del etablerade sanningar inom klassisk hockeyteori. Många tränare pratar ofta om att både ta sig in framför motståndarnas slott, vilket är framför motståndarnas mål och om att komma till avslut från bra vinklar. Så nära och centralt framför mål som möjligt. Det är också denna yta som försvaret till stor del fokuserar på att skydda. Heatmapen och graferna från rapporten bekräftar att det är från denna yta som de flesta målen görs.

En insikt man kan dra är ifall man skjuter från en dålig vinkel, så kan det vara klokare att skjuta tex på bortre benskydd på målvakten, så att man skjuter med avsikt för att det ska bli en farlig retur i stället för att själv skjuta för att det ska bli mål.
Resultaten visar att många mål görs på returer ca 12%, retur målen görs nära målet, vill man öka ett lags målskytte behöver spelarna ta sig in framför mål, vilket kan vara en obekväm plats som en del spelare ofta undviker, genom att påtala hur viktigt det är för målskyttet att ta sig in framför mål så kan man öka lagets målskörd. Detta är även viktigt för den vanligaste målformen 17,8% (10% omedvetet + 7,8% medveten styrning) av målen sker genom någon form av styrning av det ursprungliga skottet, vilket också kräver trafik framför målet.

En annan insikt från rapporten som jag aldrig tidigare har hört talas om, är att fler mål görs från vänstra sidan av målet, som oftast är målvaktens stötsida hela 9% fler mål, (stötsida, handen som målvakten håller klubban i) denna insikt kan man definitivt ha i åtanke i sitt spel, vart man placerar sig och vart man väljer att åka för att skjuta. Tittar man enbart på returmålen så görs ännu större del av målen ca 20% på vänster sida av målet. En Teori kring detta fenomen kan vara att powerplay ofta byggs primärt på högra sidan, vilket leder till att fler skott kommer utifrån på högra sidan och att returerna då kan hamna på vänstra sidan, medan målvakten sitter kvar och täcker stolpen på högra sidan. Vilket ger ett öppet mål på vänster sida, att slå in en retur ifrån. Att detta skulle vara orsaken till fler mål på vänster sida är dock inget som kan styrkas av denna rapport. Tål att nämnas är att placeringen på heatmapen visar enbart vart spelaren som skjuter står, det visar inte vart på målvakten eller i målet som skotten sedan går. Även fast skottet tas ifrån vänster sida, så är det möjligt att skjuta tex i det högra krysset. Det hade varit intressant att även undersöka vart i målen pucken går in oftast, tex om skotten oftast sitter i kryssen eller mellanbenen på målvakten.

Skottypen som leder till allra flest mål är som sagt någon form av styrning, vilket möjliggörs genom att ta sig in framför mål när skott utifrån kommer. Näst flest mål sker genom det snabba snärt skottet 8,5% av målen. Medan det klassiska slagskottet är det skott som gör minst mål, endast 4,7%. Detta beror troligtvis på att hockey går väldigt fort idag, slagskottet är det långsammaste skottsorten, det är svårt att hinna skjuta slagskott i dagens NHL. Oftast är det endast backarna uppifrån blå som emellanåt hinner skjuta slagskott, då är det långt ifrån målen vilket drar ner sannolikheten för att det blir mål, och chansen att någon hinner styra skottet på vägen ökar också när skottet tas från långt avstånd. Slagskott används även för att skjuta direkt skott, då det i stället går fortare än att ta emot en passning och sedan skjuta. Många av dessa mål som görs med slagskott sker troligtvis vid direktskott. Direktskott fångas tyvärr inte upp i denna rapport, men hade varit intressant att haft med.
Förvånansvärt stor del av målen 8,4% görs via backhandskott, enligt min erfarenhet så är denna skott typ ofta ganska förbisedd, inte så ofta man tränar på backhand skott, men med 8,4% av alla målen i

NHL så är det något som många lag bör träna oftare på.
AI prediktions modellens resultat är acceptabla, trots att modellen endast innehåller två parametrar, vinkel och avstånd, så gissar den rätt 92,80% av fallen. Det tål dock att nämna att alla skott i datan som använts resulterar i mål 7,03% av fallen, vilket innebär att om modellen hade gissat att skottet ej blev mål varje gång, hade den fått rätt 92,97% (100% - 7,03% = 92,97%) av fallen. Vilket innebär att det inte enbart går att utvärdera en modells prestanda baserat på accuracy måttet.
Ett bättre mått för denna modell är AUC score på 0,7095. Som jämförelse så är ett AUC på 0,5 ett slumpmässigt resultat, så med ett AUC på 0,7095 visar det att modellen är med marginal bättre än slumpen på att avgöra om det är ett bra skottläge eller ej. Att få 1,0 i AUC score är i princip omöjligt för denna modell som avgör om det blir mål eller ej, eftersom det är fler faktorer som påverkar än bara avstånd och vinkel, tex hur lång tid du har på dig att skjuta, om det är friläge eller om det är flera motståndare som skymmer och täcker skott, medspelare som skymmer målvakten, vilken skott typ du har möjlighet att skjuta, backhand eller handledare, om du skjuter direkt på en passning, osv, samt att du har en målvakt som du behöver överlista med skottet. Men ett AUC score på 0,7095 visar ändå att modellen har lärt sig att skilja på bra avstånd och vinkel. Flera parametrar skulle behöva läggas in för att förbättra modellen. Även mer data hade behövts, då detta endast är data från en NHL säsong.

5. Slutsatser

Detta projektarbete har lyckats med hjälp av dataanalys synliggjort på ett tydligt sätt varifrån på isen målen i NHL görs, samt vad för typ av skott som använts som resulterar i flest mål. Resultatet visar att allra flest mål 25% gjordes från avståndet 3-6 meter från målet. Desto närmare avstånd till målet desto större chans att skottet går in, 14,2% av alla skott 0-3 meter blir mål. Målchansen minskar sedan systematiskt desto längre ifrån mål skottet tas. Ca 9% fler mål gjordes från en position från vänster sida om målet jämfört med mot dess högra sida. 17,8% av målen ändrade riktning från ursprungliga skottet, och 12% av målen gjordes på returer. Snabba snärtskott blir oftare mål än långsammare slagskott.
Syftet har kunnat uppnås, med ökad kunskap om varifrån och hur mål görs i NHL, så ökar chansen att en spelare blir en bättre målgörare när denna kunskap används i praktiken, eller lärs ut av tränare. Även en maskininlärningsmodell, en Random forest modell tränades på datan och lärde sig särskilja en bra målchans från en mindre bra målchans. En sådan modell hade kunnat användas till ett realistiskt spel tex. Projektarbetet har visat att det går att kombinera maskinlärning tillsammans med sportdata, även om modellen var av en enklare modell med endast två parametrar.

6. Självutvärdering

1. Vad tycker du har varit roligast i kunskapskontrollen?
   Roligaste har varit de fria tyglarna att få använda det man har lärt sig till ett projekt eller ämne man själv är intresserad utav. Jag valde ett ämne och frågeställning som jag kunde få praktiskt användning utav, då jag fortfarande spelar hockey.

2. Hur har du hanterat utmaningar? Vilka lärdomar tar du med dig till framtida kurser?
   Några lärdomar är de agila arbetssättet, där man tar ett steg i taget, börjar med att söka efter vad för data som finns att jobba med. När man sedan hittar data, så går man igenom vad den innehåller. Eftersom jag inte samlar in datan själv, behövde jag anpassa arbetet efter vilken data som gick att få tag på. Sen när jag undersökt hur datan kunde visualiserats, så gick jag vidare med Streamlit app och maskininlärningsmodellen.

3. Vilket betyg anser du att du ska ha och varför?
   Kommer inte önska något mer än G, pga av missad deadline.

4. Något du vill lyfta till Antonio?
   Ber om ursäkt för missad deadline!